fasteR

Hyeongchan Bae

May 2022

Contents

Day 1

R과 통계분석 (Tidyverse 활용) p.4~60

1. Download

R 프로그래밍 언어. 제일 먼저 설치

- https://cran.r-project.org/bin/windows/base

RStudio R을 활용하기 위한 통합개발환경(IDE, Integrated Development Environment)

- 달리 말하면 RStudio 외에도 다양한 프로그램에서 R을 사용할 수 있음. 여러 언어를 사용하는 개발자는 VS Code 같은 단일 IDE를 활용하기도.

- https://www.rstudio.com/products/rstudio/download

Rtools 패키지를 설치하다 보면 필요한 경우(Compile)가 더러 있음

- https://cran.r-project.org/bin/windows/Rtools

Chrome Browser Selenium 파트에서 사용할 예정

- https://www.google.com/intl/ko_kr/chrome

Extra Files 인턴의 깃허브 페이지. 강의 노트, 작성 코드 등 추가적인 파일을 업로드 해둠

- https://github.com/Rlearnchan/fasteR

2. Something to Know

1) "모두 다 같은 아마추어야"

- 익숙지 않고, 오래 걸리는 게 당연해요.
- 모든 과정을 R로 수행할 필요는 없으니, 잘 안 되면 데이터를 엑셀, STATA 등으로 옮겨 처리해오셔도 좋습니다.

2) R 파일(확장자)

.R 작성한 코드

- 좌상단 Script에서 코드 작성 → 필요한 부분 실행 → 좌하단 Console 창에서 실행 결과를 확인하는 게 일반적이라, 작업 첫 파트를 저장한 것이라 볼 수 있음.
- 코드를 적은 메모장쯤 되니, **비슷한 환경**이라면 타인에게 받은 코드를 실행하기만 해도 같은 결과를 시현함.

.Rdata 작업공간 이미지

- 우상단 Environment에 기록된, 작업하며 생성된 객체, 함수, 기타 데이터들의 총체.
- 임시로 만든, 코드 실행과 무관한 object 들도 저장.

.Rhistory 작업 기록

- RStudio를 종료했다가, 다시 실행하면 이전 작업 상태가 비교적 온전히 남아있는데, 이를 위한 파일이라 하겠음.

.Rmd 마크다운 파일

- html, pdf, word 등을 만들기 위해 Markdown 문법으로 작성한, 코드 친구쯤 되는 녀석.
- 본 문서도 마크다운으로 작성. 소위 'R로 논문 쓴다' 할 때 등장.

3) 한글에 유독 취약한 R

UTF-8 인코딩 방식을 변경해주세요.

- Tools → Global Options → Code → Saving 경로.
- 타인에게 받은, 혹은 건네준 코드 파일에서 한글이 깨져 보인다면 대체로 이 문제.
- File → Reopen with Encoding 기능을 활용해 대처하는 방법도 있음.

Library Path 패키지 설치 경로에 한글 네이밍이 없도록 해주세요.

```
.libPaths() # 첫 번째가 default. 개인 폴더가 설정돼 두 개 나오기도 한다.
```

```
## [1] "C:/Program Files/R/R-4.2.0/library"
```

- (윈도우 기준 예시) 만일 [2] “C:/Users/**사용자 이름**/Documents/R/win-library/4.2.0” 경로에 한글이 포함된다면, 패키지를 다룰 때마다 오류 사인을 접할 공산이 큼.
- 새로 계정을 만들지 않는 이상, **사용자 이름** 구간 폴더 명은 변경하기도 어려움.
- 다음과 같이 **사용자 이름**이 없는 기본(공용) 라이브러리를 default로 설정하길 권장.

```
Sys.setenv('R_LIBS_USER' = 'C:/Program Files/R/R-4.2.0/library')
# R의 '개인' 세팅을 앞서 발견한 '기본(공용)' 경로로 덮어쓰기.

.libPaths('R_LIBS_USER') # 바뀐 '개인 라이브러리'를 패키지 설치 경로로 설정.
```

```
.libPaths() # 하나의 경로로 잘 세팅되고,
```

```
## [1] "C:/Program Files/R/R-4.2.0/library"
```

```
.libPaths() == Sys.getenv('R_LIBS_USER') # 개인 라이브러리 경로와도 일치
```

```
## [1] TRUE
```

4) ?, ?? 사용법

? 모르는 함수 검색하기

```
?print
```

- 대부분의 함수는 R Documentation 이라 해서 정의와 기능, 인자, 간단한 사용 예시 등을 요약해둔 페이지를 가지고 있음.
- 예컨대 print() 함수를 자세히 알고 싶다면, 위에서 처럼 ? 하나 붙여서 실행하면 됨.

?? 모르는 개념, 워딩 검색하기

```
??print
```

- 하지만 함수 이름조차 모르거나, 기능을 연상할 키워드 정도만 간신히 아는 경우도 많음.
- ??는 모든 R Documentation 에서 해당 단어가 포함된 것을 모두 골라 보여줌.
- 두 가지를 적절히 섞어 사용하는 게 좋음.

5) 구글링

- 사실 구글은 모든 걸 알고 있음.
- str_dectect() 식으로 함수 이름 자체를 검색하면 국내외 사용자들이 포스팅한 글을 찾아보기 편함.
- warning 혹은 error 사인은 해당 문구를 적당히 복사해 구글에 그대로 쳐보는 게 좋음.
- stackoverflow 같은 개발자 커뮤니티 게시물이 주로 나올 텐데, 같은 문제로 고민한 사람들이 꽤 많았기 때문.

3. Basic Function

1) 숫자 계산

```
3+4-7/3 # 달리 명령어가 필요하진 않으나,
```

```
## [1] 4.666667
```

```
print(3+4-7/3) # print() 함수를 사용할 수도 있음
```

```
## [1] 4.666667
```

```
print(3+4-7/3, digits = 3) # 세 번째 자리에서 반올림
```

```
## [1] 4.67
```

```
rnorm(n = 5, mean = 0, sd = 1) # n(0, 1) 분포에서 5개 난수 생성
```

```
## [1] -1.0174670  0.3283890 -0.4865759  0.9084495  0.1941311
```

```
stats::rnorm(n = 5, mean = 0, sd = 1) # stats 패키지의 rnorm() 함수
```

```
## [1]  0.5971627 -1.0055673 -0.9766609  0.4137973 -1.0911547
```

- 기본 패키지, 혹은 library() 로 장착한 패키지의 함수는 :: 표기를 사용하지 않아도 됨.
- 여러 패키지를 동시에 사용하는 경우, 유사한 이름의 함수 간 혼동을 피하기 위해 :: 방식을 사용하기도 함.

```
set.seed(seed = 10)
```

- reproducibility 위해서 난수 생성 규칙을 set.seed()로 부여.

```
rnorm(5, 0, 1)
```

```
## [1]  0.01874617 -0.18425254 -1.37133055 -0.59916772  0.29454513
```

2) 텍스트

```
'banana' # 작은 따옴표
```

```
## [1] "banana"
```

```
"banana" # 큰 따옴표 모두 사용 가능
```

```
## [1] "banana"
```

```
class('banana') # 문자 클래스
```

```
## [1] "character"
```

- class() 함수는 자주 쓰니 기억해 둘 필요가 있음.

```
paste0('이제와', '뒤늦게', '무엇을 더 보태려하나') # 문자열 붙여서 하나로 만듦
```

```
## [1] "이제와뒤늦게무엇을 더 보태려하나"
```

```
paste0('이제와 ', '뒤늦게 ', '무엇을 더 보태려하나') # 띄어쓰기를 포함해서 붙이는 게 요령
```

```
## [1] "이제와 뒤늦게 무엇을 더 보태려하나"
```

```
paste('이제와', '뒤늦게', '무엇을 더 보태려하나') # 한 칸씩 띄어쓰는 게 default인 함수
```

```
## [1] "이제와 뒤늦게 무엇을 더 보태려하나"
```

```
paste('이제와', '뒤늦게', '무엇을 더 보태려하나', sep = '둠칫') # 사실 sep = ' ' 인자가 숨어있던 것. 바꿀 수도 있음.
```

```
## [1] "이제와둠칫뒤늦게둠칫무엇을 더 보태려하나"
```

3) 객체

```
BR31 = 'Alien Mom' # 텍스트를 BR31 객체에 저장


br31 = 'Mint Choco' # 텍스트를 br31 객체에 저장
```

```
BR31
```

[1] "Alien Mom"

```
br31
```

[1] "Mint Choco"

```
paste('Which do you prefer', BR31, 'or', br31) # 객체명을 입력하면 담긴 것을 가져다 씀.
```

[1] "Which do you prefer Alien Mom or Mint Choco"

- 객체 명을 지을 땐 **대소문자 구별**, 그리고 **첫 글자엔 숫자 및 기호 불가** 특성을 고려해야 함.

4) 벡터

```
Yunha = c(4, 8, 6) # 숫자 세 개를 벡터로 묶어 저장
```

```
Yunha
```

[1] 4 8 6

```
class(Yunha) # 숫자 속성이 그대로 남아 있음
```

[1] "numeric"

```
Yunha = c('Password', 4, 8, 6) # 원소가 하나라도 character가 섞이면
```

```
Yunha # 따옴표 찍힌 것부터 느낌이 다르고,
```

[1] "Password" "4"   "8"   "6"

```
class(Yunha) # 얄짤없이 전부 character로 저장
```

[1] "character"

5) 행렬

```
matrix(data = c(1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12), nrow = 3, ncol = 4)
```

[,1] [,2] [,3] [,4]
[1,]   1   4   7   10
[2,]   2   5   8   11
[3,]   3   6   9   12

```
matrix(data = c(1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12), nrow = 3, ncol = 4, dimnames = list(c('가', '나', '다'), c('A', 'B', 'C',
```

```
##    A B C  D
## 가 1 4 7 10
## 나 2 5 8 11
## 다 3 6 9 12
```

```
matrix(data = c(1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12),
       dimnames = list(c('가', '나', '다'), c('A', 'B', 'C', 'D')),
       nrow = 3, ncol = 4) # 코드가 슬슬 길어지니, 엔터를 적극 활용.
```

```
##    A B C  D
## 가 1 4 7 10
## 나 2 5 8 11
## 다 3 6 9 12
```

- 마지막 코드에선 인자들의 순서가 조금 다른데, 이는 인자명을 지정해줬기 때문에 가능한 것.
- 지정만 잘 돼있으면 섞여도 상관 없음.

```
mat <- matrix(1:12, 3, 4) # matrix() 함수의 처음 세 인자가 data, nrow, ncol 이므로 필요한 값만 입력.

colnames(mat) <- c('A', 'B', 'C', 'D') # 열이름 덮어쓰기

rownames(mat) <- c('가', '나', '다') # 행이름 덮어쓰기
```

- 하다 보면 쉬운 길을 찾아가게 됨.
- 1:12는 seq(from = 1, to = 12, by = 1) 과 같음.
- <-는 =과 같음.

```
mat
```

```
##    A B C  D
## 가 1 4 7 10
## 나 2 5 8 11
## 다 3 6 9 12
```

```
class(mat)
```

```
## [1] "matrix" "array"
```

6) 데이터프레임

```
윤하 <- as.data.frame(Yunha)


matthew <- as.data.frame(mat)
```

- as.data.frame() 함수는 벡터, 행렬 등을 인자로 받음.

```
윤하
```

```
##      Yunha
## 1 Password
## 2        4
## 3        8
## 4        6
```

```
class(윤하)
```

```
## [1] "data.frame"
```

- 데이터프레임은 row = observation, column = variable 개념이라, 열 이름을 웬만하면 채우려고 하는데, 여기선 character vector 이름인 Yunha를 차용한 모습.
- 벡터 이름 : 벡터 내용 = 변수 이름 : 관측치 느낌으로 해석한 듯.

```
matthew
```

```
##    A B C  D
## 가 1 4 7 10
## 나 2 5 8 11
## 다 3 6 9 12
```

```
class(matthew)
```

```
## [1] "data.frame"
```

7) 인덱싱

```
Yunha[2] # Yunha 벡터의 두 번째 요소
```

```
## [1] "4"
```

```
mat[, 1] # mat 행렬의 첫 열
```

```
## 가 나 다
```

```
##  1  2  3
```

```
mat[2, 2] # mat 행렬의 (2, 2) 요소
```

```
## [1] 5
```

```
matthew$A # matthew 데이터프레임의 변수 A에 속한 값
```

```
## [1] 1 2 3
```

```
matthew[2, 2] # matthew 데이터프레임의 (2, 2) 요소
```

```
## [1] 5
```

- 데이터프레임의 인덱싱이 조금 더 깔끔한 느낌.
- 실제 작업에도 용이한바, R의 데이터분석은 대개 데이터프레임 형태를 사용.
- 이를 Pyhton에서 구현하기 위해 Pandas 라이브러리를 만듦.

4. Others

주석처리

- 코드 설명 작성 : print(a) # a를 출력한다
- 해당 부분을 실행에서 제외 : #print(a)

업데이트 R, RStudio 모두 꾸준히 새 버전이 나오지만, 구 버전을 사용해도 큰 문제 없음

- R은 새로 설치하고 구 버전을 삭제하는 게 제일 간편. RStudio는 알아서 최신의 R을 인식해 사용.
- RStudio는 Help → Check for Updates 기능을 활용.
- 패키지는 Tools → Check for Package Updates

Working Directory 작업 공간(폴더)을 지정하자

- 외부 파일을 불러오거나, 외부로 저장할 일이 많음.
- R은 기본적으로 C:/Users/Document, 즉 내 문서 폴더를 기본 작업 공간으로 인식.
- 매번 내 문서 폴더에서 작업을 할 순 없는 노릇.
- setwd(folder) 함수의 folder 인자에 원하는 경로를 입력.

```
setwd('C:₩Users₩KIET₩Documents₩GitHub') # 그대로 붙여넣으면 안 되고,

setwd('C:/Users/KIET/Documents/GitHub') # ₩를 /로 교체해줘야 함.
```

- R에서 ₩ 문자는 정규표현식의 하나로, 슬래시 표현 외에 약속된 다른 기능을 담당함.
- 그런 차에 /를 경로 기술에 대신 사용하는 듯.

5. Quiz

초급 다음의 행렬을 만들어보자

```
##        var1 var2 var3
## Case #1   12   21   32
## Case #2   17   22   34
## Case #3   19   25   35
```

중급 datasets::iris 데이터를 가져와 다음을 해결해보자

1) iris 변수의 이름을 names() 함수로 확인하라.
2) iris 관찰값, 변수의 개수를 dim(), nrow(), length() 함수로 확인하라.
3) iris 처음 세 줄과 마지막 세 줄을 head(), tail() 함수로 출력하라.

고급 다음 코드의 문제점을 지적해보자. 수정본을 참고해도 좋다.

```
I-DLE_MEMBERS <- c('소연', '미연', '민니', '우기', '슈화')

I-DLE_LYLICS <- c('Look at you 넌 못 감당해 날',
                  'I got to drink up now 네가 싫다 해도 좋아',
                  'Why are you cranky, boy? 뭘 그리 찡그려 너',
                  '미친 연이라 말해 What's the loss to me ya',
                  '사랑 그깟 거 따위 내 몸에 상처 하나도 어림없지',
                  'Ye I'm a Tomboy (Umm ah umm)',
                  'Ye I'll be the Tomboy (Umm ah)')

TOMBOY <- data.frame(I-DLE_MEMBERS, I-DLE_LYLICS)
```

```
## Error: <text>:7:35: 예상하지 못한 기호(symbol)입니다.
## 6:                  'Why are you cranky, boy? 뭘 그리 찡그려 너',
## 7:                  '미친 연이라 말해 What's
##                                     ^
```

```
IDLE_MEMBERS <- c('소연', '미연', '민니', '우기', '슈화')
```

```
IDLE_LYLICS <- c('Look at you 넌 못 감당해 날',
                 'I got to drink up now 네가 싫다 해도 좋아',
                 'Why are you cranky, boy? 뭘 그리 찡그려 너',
                 "미친 연이라 말해 What's the loss to me ya",
                 '사랑 그깟 거 따위 내 몸에 상처 하나도 어림없지',
                 "Ye I'm a Tomboy (Umm ah umm)",
                 "Ye I'll be the Tomboy (Umm ah)")

TOMBOY <- data.frame(MEMBERS = IDLE_MEMBERS[c(3, 4, 1, 2, 4, 3, 5)],
                     LYLICS = IDLE_LYLICS)

TOMBOY
```

```
##   MEMBERS                                LYLICS
## 1    민니                 Look at you 넌 못 감당해 날
## 2    우기      I got to drink up now 네가 싫다 해도 좋아
## 3    소연     Why are you cranky, boy? 뭘 그리 찡그려 너
## 4    미연      미친 연이라 말해 What's the loss to me ya
## 5    우기 사랑 그깟 거 따위 내 몸에 상처 하나도 어림없지
## 6    민니                  Ye I'm a Tomboy (Umm ah umm)
## 7    슈화                Ye I'll be the Tomboy (Umm ah)
```

Day 2

R과 통계분석 (Tidyverse 활용) p.102~146

파이썬 머신러닝 판다스 데이터 분석 p.2~55

1. What is Tidyverse

Package for Packages 데이터 분석을 위한 패키지의 모음집

```
install.packages('tidyverse') # library() 와는 달리 따옴표를 붙여줘야 함, 이하에선 인스톨 생략
```

```
library(tidyverse) # tidyverse 패키지 장착
```

```
## -- Attaching packages --------------------------------------- tidyverse 1.3.1 --
## v ggplot2 3.3.6     v purrr   0.3.4
## v tibble  3.1.6     v dplyr   1.0.9
```

```
## v tidyr   1.2.0     v stringr 1.4.0
## v readr   2.1.2     v forcats 0.5.1

## -- Conflicts ---------------------------------------- tidyverse_conflicts() --
## x dplyr::filter() masks stats::filter()
## x dplyr::lag()    masks stats::lag()
```

- ggplot2(시각화), dplyr(조작), stringr(텍스트), tibble(데이터프레임) 등의 패키지를 한 번에 로드, 장착할 수 있음.
- Conflicts 란에 제시되는 건 이미 라이브러리를 장착해 사용 중인 함수와 이름이 겹치는 케이스.
- 이제 filter() 함수는 stats::filter()가 아니라 dplyr::mutate()를 우선 선택.
- stats::filter() 식으로 풀네임을 써야 해당 함수 사용 가능.

And then, and then 직관적인 연결 작업

- tidyverse 계열 함수들은 첫 번째 입력값을 data로 통일. function(data, actions) 개념.
- pipe operator %>%는 앞선 작업 결과물을 다음 함수의 첫 요소로 대입하는 기능
- x %>% f(y) → f(x, y) 식으로 결합 사용하는 게 일반적.

2. Exercise : PSI 보도자료

2022년 2월 PSI https://www.kiet.re.kr/kiet_web/?sub_num=1503&state=view&idx=59127&ord=0

1) 데이터 로드

```
library(openxlsx) # openxlsx 패키지 장착


read.xlsx('PSI 연습용.xlsx')
```

```
##   연도 월          구분 응답수  경기현황  경기전망 시장판매현황
## 1  2022  2       00_전체    235  96.17021 110.63830    102.55319
## 2  2022  2        01_ICT     86  94.18605 110.46512    100.00000
## 3  2022  2       02_장비     76 102.63158 110.52632    107.89474
## 4  2022  2       03_소재     52  82.69231 111.53846     92.30769
## 5  2022  2       04_전자     42 109.52381 135.71429    109.52381
## 6  2022  2       05_가전     16 106.25000 143.75000    100.00000
## 7  2022  2     06_핸드폰     26 111.53846 130.76923    115.38462
## 8  2022  2  07_디스플레이     21  85.71429  90.47619     76.19048
```

```
## 9  2022  2        08_반도체     23  73.91304  82.60870    104.34783
## 10 2022  2          09_기계     22 100.00000 100.00000    100.00000
## 11 2022  2        10_자동차     34 102.94118 120.58824    114.70588
## 12 2022  2          11_조선     20 105.00000 105.00000    105.00000
## 13 2022  2          12_섬유     16  75.00000 112.50000     81.25000
## 14 2022  2          13_철강     14 100.00000 121.42857    100.00000
## 15 2022  2          14_화학     22  77.27273 104.54545     95.45455
## 16 2022  2     15_바이오헬스     21 114.28571 109.52381    119.04762
## 17 2022  2     16_애널리스트    105  93.33333 119.04762    103.80952
## 18 2022  2 17_공공기관및기타    130  98.46154 103.84615    101.53846
## 19 2022  2     18_애널리스트    105  93.33333 119.04762    103.80952
## 20 2022  2      19_공공기관     85  97.64706 104.70588    102.35294
## 21 2022  2          20_기타     45 100.00000 102.22222    100.00000
##    시장판매전망  수출현황 수출전망 생산수준현황 생산수준전망 재고수준현황
## 1     114.46809 106.38298 122.9787    105.95745     122.5532    107.65957
## 2     112.79070 110.46512 127.9070    112.79070     125.5814     96.51163
## 3     113.15789 118.42105 125.0000    107.89474     127.6316    128.94737
## 4     121.15385  82.69231 119.2308     88.46154     115.3846     96.15385
## 5     128.57143 133.33333 138.0952    123.80952     123.8095    102.38095
## 6     118.75000 112.50000 125.0000    112.50000     112.5000    100.00000
## 7     134.61538 146.15385 146.1538    130.76923     130.7692    103.84615
## 8      90.47619  80.95238 109.5238     80.95238     123.8095     80.95238
## 9     104.34783  95.65217 126.0870    121.73913     130.4348    100.00000
## 10    100.00000 113.63636 118.1818     95.45455     113.6364    104.54545
## 11    126.47059 120.58824 129.4118    105.88235     126.4706    167.64706
## 12    105.00000 120.00000 125.0000    125.00000     145.0000     90.00000
## 13    112.50000  87.50000 125.0000     87.50000     118.7500     93.75000
## 14    135.71429  85.71429 128.5714     71.42857     107.1429    100.00000
## 15    118.18182  77.27273 109.0909    100.00000     118.1818     95.45455
## 16    109.52381 104.76190 104.7619    114.28571     109.5238    104.76190
## 17    121.90476 107.61905 132.3810    110.47619     137.1429    107.61905
## 18    108.46154 105.38462 115.3846    102.30769     110.7692    107.69231
## 19    121.90476 107.61905 132.3810    110.47619     137.1429    107.61905
## 20    110.58824 108.23529 118.8235    101.17647     111.7647    110.58824
## 21    104.44444 100.00000 108.8889    104.44444     108.8889    102.22222
##    재고수준전망 신규수주현황 신규수주전망 투자액현황 투자액전망 채산성현황
```

```
## 1    109.78723   104.87805   100.00000  108.93617   115.7447   86.38298
## 2     98.83721          NA          NA  101.16279   112.7907   87.20930
## 3    131.57895    90.00000   100.00000  115.78947   122.3684   98.68421
## 4     98.07692          NA          NA  105.76923   109.6154   61.53846
## 5    102.38095          NA          NA  102.38095   102.3810  107.14286
## 6     93.75000          NA          NA  100.00000   100.0000  112.50000
## 7    107.69231          NA          NA  103.84615   103.8462  103.84615
## 8     85.71429          NA          NA   90.47619   114.2857   76.19048
## 9    104.34783          NA          NA  108.69565   130.4348   60.86957
## 10   104.54545          NA          NA   95.45455   100.0000   77.27273
## 11   167.64706          NA          NA  132.35294   141.1765  108.82353
## 12   100.00000    90.00000   100.00000  110.00000   115.0000  105.00000
## 13    93.75000          NA          NA   87.50000    93.7500   62.50000
## 14   100.00000          NA          NA  128.57143   128.5714   78.57143
## 15   100.00000          NA          NA  104.54545   109.0909   50.00000
## 16   104.76190   119.04762   100.00000  123.80952   119.0476  100.00000
## 17   114.28571    93.33333   100.00000  109.52381   123.8095   81.90476
## 18   106.15385   111.53846   100.00000  108.46154   109.2308   90.00000
## 19   114.28571    93.33333   100.00000  109.52381   123.8095   81.90476
## 20   110.58824   113.33333   106.66667  107.05882   109.4118   88.23529
## 21    97.77778   109.09091    90.90909  111.11111   108.8889   93.33333
##    채산성전망
## 1    97.44681
## 2   101.16279
## 3   101.31579
## 4    82.69231
## 5   126.19048
## 6   125.00000
## 7   126.92308
## 8    76.19048
## 9    78.26087
## 10   77.27273
## 11  105.88235
## 12  120.00000
## 13   62.50000
## 14   92.85714
```

```
## 15   90.90909
## 16  104.76190
## 17  103.80952
## 18   92.30769
## 19  103.80952
## 20   89.41176
## 21   97.77778
```

```
PSI_ORIGINAL <- read.xlsx('PSI 연습용.xlsx') %>%
  tibble() # 엑셀 파일을 읽어서 PSI_ORIGINAL 이라 명명.


PSI_ORIGINAL # tibble을 사용하니, 직전보단 깔끔하게 저장된다. class 표시는 덤.
```

```
## # A tibble: 21 x 20
##    연도    월 구분  응답수 경기현황 경기전망 시장판매현황 시장판매전망 수출현황
##   <dbl> <dbl> <chr>  <dbl>    <dbl>    <dbl>       <dbl>       <dbl>    <dbl>
##  1  2022     2 00_~     235     96.2    111.        103.        114.     106.
##  2  2022     2 01_I~     86     94.2    110.        100         113.     110.
##  3  2022     2 02_~      76    103.     111.        108.        113.     118.
##  4  2022     2 03_~      52     82.7    112.         92.3       121.      82.7
##  5  2022     2 04_~      42    110.     136.        110.        129.     133.
##  6  2022     2 05_~      16    106.     144.        100         119.     112.
##  7  2022     2 06_~      26    112.     131.        115.        135.     146.
##  8  2022     2 07_~      21     85.7     90.5        76.2        90.5     81.0
##  9  2022     2 08_~      23     73.9     82.6        104.        104.     95.7
## 10  2022     2 09_~      22    100      100          100         100      114.
## # ... with 11 more rows, and 11 more variables: 수출전망 <dbl>,
## #   생산수준현황 <dbl>, 생산수준전망 <dbl>, 재고수준현황 <dbl>,
## #   재고수준전망 <dbl>, 신규수주현황 <dbl>, 신규수주전망 <dbl>,
## #   투자액현황 <dbl>, 투자액전망 <dbl>, 채산성현황 <dbl>, 채산성전망 <dbl>
```

- read.xlsx() 함수의 첫 인자는 xlsxFile 으로, 해당 파일의 경로를 입력해야 함.
- 정확한 경로와 이름을 적으면서, 확장자 명을 꼭 포함할 것.
- 두 번째 인자는 sheetName, 미지정 시 첫 번째 시트를 로드한다. 다중 시트로 이뤄진 엑셀 파일이라면 시트 이름을 지정해주는 게 유용.
- 데이터 프레임을 가져올 땐 tibble() 함수를 거쳐서 단정하게 만들자.
- 여담으로 xlsxFile, sheetName 처럼 영문 가운데 capital을 섞어주는 걸 camel 표기법이라 함.

2) 훑어보기

```
PSI_ORIGINAL %>% head() # 상위 순번 관측값만 표시, default = 6개
```

```
## # A tibble: 6 x 20
##    연도    월 구분   응답수 경기현황 경기전망 시장판매현황 시장판매전망 수출현황
##   <dbl> <dbl> <chr>  <dbl>    <dbl>    <dbl>       <dbl>       <dbl>    <dbl>
## 1  2022     2 00_전~    235     96.2     111.        103.        114.     106.
## 2  2022     2 01_ICT     86     94.2     110.        100         113.     110.
## 3  2022     2 02_장~     76    103.      111.        108.        113.     118.
## 4  2022     2 03_소~     52     82.7     112.         92.3       121.      82.7
## 5  2022     2 04_전~     42    110.      136.        110.        129.     133.
## 6  2022     2 05_가~     16    106.      144.        100         119.     112.
## # ... with 11 more variables: 수출전망 <dbl>, 생산수준현황 <dbl>,
## #   생산수준전망 <dbl>, 재고수준현황 <dbl>, 재고수준전망 <dbl>,
## #   신규수주현황 <dbl>, 신규수주전망 <dbl>, 투자액현황 <dbl>, 투자액전망 <dbl>,
## #   채산성현황 <dbl>, 채산성전망 <dbl>
```

```
PSI_ORIGINAL %>% names() # 변수 이름
```

```
##  [1] "연도"        "월"          "구분"        "응답수"      "경기현황"
##  [6] "경기전망"    "시장판매현황" "시장판매전망" "수출현황"    "수출전망"
## [11] "생산수준현황" "생산수준전망" "재고수준현황" "재고수준전망" "신규수주현황"
## [16] "신규수주전망" "투자액현황"  "투자액전망"  "채산성현황"  "채산성전망"
```

```
PSI_ORIGINAL %>% dim() # dimension
```

```
## [1] 21 20
```

```
PSI_ORIGINAL$구분 # 데이터 '구분' 열에 담긴 관측값들
```

```
##  [1] "00_전체"         "01_ICT"          "02_장비"
##  [4] "03_소재"         "04_전자"         "05_가전"
##  [7] "06_핸드폰"       "07_디스플레이"   "08_반도체"
## [10] "09_기계"         "10_자동차"       "11_조선"
## [13] "12_섬유"         "13_철강"         "14_화학"
## [16] "15_바이오헬스"   "16_애널리스트"   "17_공공기관및기타"
## [19] "18_애널리스트"   "19_공공기관"     "20_기타"
```

```
PSI_ORIGINAL[2, ] # 데이터 2열 관측값
```

```
## # A tibble: 1 x 20
##    연도    월 구분   응답수 경기현황 경기전망 시장판매현황 시장판매전망 수출현황
##   <dbl> <dbl> <chr>  <dbl>    <dbl>    <dbl>        <dbl>        <dbl>    <dbl>
## 1  2022     2 01_ICT     86     94.2     110.          100          113.     110.
## # ... with 11 more variables: 수출전망 <dbl>, 생산수준현황 <dbl>,
## #   생산수준전망 <dbl>, 재고수준현황 <dbl>, 재고수준전망 <dbl>,
## #   신규수주현황 <dbl>, 신규수주전망 <dbl>, 투자액현황 <dbl>, 투자액전망 <dbl>,
## #   채산성현황 <dbl>, 채산성전망 <dbl>
```

3) 응답자 비율 구하기

```
PSI_ORIGINAL %>% # 원본 데이터에서
 select(구분, 응답수) %>% # 구분, 응답수 열을 고른 다음
 mutate(비율 = 응답수/235*100) # 새로운 열을 추가하는데, 얘는 응답수/235*100 계산값임.
```

```
## # A tibble: 21 x 3
##    구분         응답수   비율
##    <chr>         <dbl>  <dbl>
##  1 00_전체         235 100
##  2 01_ICT           86  36.6
##  3 02_장비          76  32.3
##  4 03_소재          52  22.1
##  5 04_전자          42  17.9
##  6 05_가전          16   6.81
##  7 06_핸드폰        26  11.1
##  8 07_디스플레이    21   8.94
##  9 08_반도체        23   9.79
## 10 09_기계          22   9.36
## # ... with 11 more rows
```

- select(data_table, columns, ...) 원하는 column 고르기. 위치 인덱스나 변수 명을 적으면 됨.
- select(-1) 식으로 쓰면, 첫 번째 열을 제외하고 모두 선택.
- 변수 명에 띄어쓰기가 있다면, 해당 이름 전체를 따옴표나 accent 기호로 감싸야 함.
- mutate(data_table, var_name = new_data, ...) 새로운 열 만들기(덮어쓰기 가능).

```
PSI_RATE.1 <- PSI_ORIGINAL %>%
 select(구분, 응답수) %>%
```

```
  mutate(비율 = 응답수/235*100) # 앞서 만든 데이터를 하나의 객체로 저장해두자.

PSI_RATE.2 <- PSI_RATE.1 %>% # 아까 하던 거에서
  mutate(비율 = round(비율, digits = 1)) %>% # 비율 값은 반올림해서 덮어씌우고
  slice(1:18) # 필요한 row만 선택하자.

PSI_RATE.2 # 좋긴 한데, 보도자료는 업종 순서가 달라서 붙여넣기가 애매.
```

```
## # A tibble: 18 x 3
##    구분            응답수  비율
##    <chr>           <dbl> <dbl>
##  1 00_전체           235 100
##  2 01_ICT             86  36.6
##  3 02_장비            76  32.3
##  4 03_소재            52  22.1
##  5 04_전자            42  17.9
##  6 05_가전            16   6.8
##  7 06_핸드폰          26  11.1
##  8 07_디스플레이      21   8.9
##  9 08_반도체          23   9.8
## 10 09_기계            22   9.4
## 11 10_자동차          34  14.5
## 12 11_조선            20   8.5
## 13 12_섬유            16   6.8
## 14 13_철강            14   6
## 15 14_화학            22   9.4
## 16 15_바이오헬스      21   8.9
## 17 16_애널리스트      105  44.7
## 18 17_공공기관및기타  130  55.3
```

- slice(data_table, rows, ...) 원하는 row 고르기.

```
PSI_RATE.2[c(2, 3, 4, 9, 8, 5, 7, 6, 11, 12, 10, 15, 14, 13, 16, 17, 18), ] # 순서를 바꾸면 되지
```

```
## # A tibble: 17 x 3
##    구분            응답수  비율
##    <chr>           <dbl> <dbl>
##  1 01_ICT             86  36.6
```

```
##  2 02_장비            76  32.3
##  3 03_소재            52  22.1
##  4 08_반도체          23   9.8
##  5 07_디스플레이      21   8.9
##  6 04_전자            42  17.9
##  7 06_핸드폰          26  11.1
##  8 05_가전            16   6.8
##  9 10_자동차          34  14.5
## 10 11_조선            20   8.5
## 11 09_기계            22   9.4
## 12 14_화학            22   9.4
## 13 13_철강            14   6
## 14 12_섬유            16   6.8
## 15 15_바이오헬스      21   8.9
## 16 16_애널리스트      105  44.7
## 17 17_공공기관및기타  130  55.3
```

```
APPENDIX.1 <- PSI_RATE.2[c(2, 3, 4, 9, 8, 5, 7, 6, 11, 12, 10, 15, 14, 13, 17, 18), ] # 완성품 저장
```

- 완성품, 중간 작업물은 네이밍 규칙을 달리 가져가는 게 편하다.
- 객체를 왕창 만들다보면 헷갈릴 일이 생기기 마련.

4) 기상도 만들기

```
PSI_WEATHER.1 <- PSI_ORIGINAL %>%
  select(3, '경기현황', `시장판매현황`, 수출현황,
         생산수준현황, 투자액현황, 채산성현황) # 인덱스, '변수명', `변수명`, 변수명 모두 가능


PSI_WEATHER.1
```

```
## # A tibble: 21 x 7
##    구분       경기현황 시장판매현황 수출현황 생산수준현황 투자액현황 채산성현황
##    <chr>       <dbl>       <dbl>    <dbl>       <dbl>     <dbl>     <dbl>
##  1 00_전체      96.2        103.     106.        106.      109.      86.4
##  2 01_ICT       94.2        100      110.        113.      101.      87.2
##  3 02_장비      103.        108.     118.        108.      116.      98.7
##  4 03_소재      82.7        92.3     82.7        88.5      106.      61.5
##  5 04_전자      110.        110.     133.        124.      102.      107.
```

```
##  6 05_가전       106.       100     112.       112.      100       112.
##  7 06_핸드폰     112.       115.    146.       131.      104.      104.
##  8 07_디스플~     85.7       76.2    81.0       81.0      90.5      76.2
##  9 08_반도체      73.9      104.     95.7      122.      109.      60.9
## 10 09_기계       100        100     114.       95.5      95.5      77.3
## # ... with 11 more rows
```

```
PSI_WEATHER.2 <- PSI_WEATHER.1 %>%
  mutate_at(.vars = 2:7, .funs = round) # 2:7열 관측값에 반올림 적용

PSI_WEATHER.2
```

```
## # A tibble: 21 x 7
##    구분      경기현황 시장판매현황 수출현황 생산수준현황 투자액현황 채산성현황
##    <chr>        <dbl>       <dbl>    <dbl>       <dbl>     <dbl>     <dbl>
##  1 00_전체         96         103      106         106       109        86
##  2 01_ICT          94         100      110         113       101        87
##  3 02_장비         103        108      118         108       116        99
##  4 03_소재         83         92       83          88        106        62
##  5 04_전자         110        110      133         124       102        107
##  6 05_가전         106        100      112         112       100        112
##  7 06_핸드폰       112        115      146         131       104        104
##  8 07_디스플~       86         76       81          81        90         76
##  9 08_반도체        74         104      96         122       109        61
## 10 09_기계         100        100      114          95        95         77
## # ... with 11 more rows
```

- mutate_at(data_table, .vars, .funs, ...) 는 mutate()의 고급 버전.
- .funs에 입력한 함수를 .vars에 입력한 변수에 일괄 적용하고 덮어씌움.

```
PSI_WEATHER.3 <- PSI_WEATHER.2[c(1, 9, 8, 5, 7, 6, 11, 12, 10, 15, 14, 13, 16, 2, 3, 4), ]

colnames(PSI_WEATHER.3) <- c('구분', '업황', '내수', '수출', '생산수준', '투자액', '채산성')

PSI_WEATHER.3 # 갖다 붙이려 했는데, 숫자가 묘하게 다름
```

```
## # A tibble: 16 x 7
##    구분          업황  내수  수출 생산수준 투자액 채산성
##    <chr>        <dbl> <dbl> <dbl>   <dbl>  <dbl>  <dbl>
```

```
##  1 00_전체        96   103   106     106    109     86
##  2 08_반도체       74   104    96     122    109     61
##  3 07_디스플레이    86    76    81      81     90     76
##  4 04_전자        110   110   133     124    102    107
##  5 06_핸드폰       112   115   146     131    104    104
##  6 05_가전        106   100   112     112    100    112
##  7 10_자동차       103   115   121     106    132    109
##  8 11_조선        105   105   120     125    110    105
##  9 09_기계        100   100   114      95     95     77
## 10 14_화학         77    95    77     100    105     50
## 11 13_철강        100   100    86      71    129     79
## 12 12_섬유         75    81    88      88     88     62
## 13 15_바이오헬스   114   119   105     114    124    100
## 14 01_ICT         94   100   110     113    101     87
## 15 02_장비        103   108   118     108    116     99
## 16 03_소재         83    92    83      88    106     62
```

- R의 round() 함수는 round(0.5) = 0 으로 계산해버림.
- 그럼 어떻게 해야할까. 뭐 구글 가야죠.

```
round2 = function(x, n = 0) {

  posneg = sign(x)
  z = abs(x)*10^n
  z = z + 0.5 + sqrt(.Machine$double.eps)
  z = trunc(z)
  z = z/10^n
  z*posneg

} # 구글 멋쟁이가 만들어둔 함수를 그대로 긁어오자

round(0.5) ; round2(0.5, 0) # 두 번째 인자 n은 digits
```

```
## [1] 0
```

```
## [1] 1
```

- function(factors, ...) { what to do } 식으로 사용자 함수를 정의할 수 있음.
- 아래 mutate_at() 함수에서 오류가 나서, n의 default 값만 function(x, n = 0) 으로 수정하자.

- tidyverse 함수에선 직전 작업 값 '.' 으로 표현한다. .$구분 으로 적어도 해당 흐름 내에선 '작업 중이던 데이터프레임의 구분 열' 쯤으로 인식하는 셈.
- .vars, .funs도 유사한 맥락의 네이밍인데, 설명하는 건 강의 레벨을 벗어나므로 스킵.

```
PSI_WEATHER.2 <- PSI_WEATHER.1 %>%
  mutate_at(.vars = 2:7, .funs = round2) # 반올림 함수 교체

PSI_WEATHER.3 <- PSI_WEATHER.2[c(1, 9, 8, 5, 7, 6, 11, 12, 10, 15, 14, 13, 16, 2, 3, 4), ]

colnames(PSI_WEATHER.3) <- c('구분', '업황', '내수', '수출', '생산수준', '투자액', '채산성')

PSI_WEATHER.3
```

```
## # A tibble: 16 x 7
##    구분          업황  내수  수출 생산수준 투자액 채산성
##    <chr>        <dbl> <dbl> <dbl>   <dbl>  <dbl>  <dbl>
##  1 00_전체         96   103   106     106    109     86
##  2 08_반도체       74   104    96     122    109     61
##  3 07_디스플레이   86    76    81      81     90     76
##  4 04_전자        110   110   133     124    102    107
##  5 06_핸드폰      112   115   146     131    104    104
##  6 05_가전        106   100   113     113    100    113
##  7 10_자동차      103   115   121     106    132    109
##  8 11_조선        105   105   120     125    110    105
##  9 09_기계        100   100   114      95     95     77
## 10 14_화학         77    95    77     100    105     50
## 11 13_철강        100   100    86      71    129     79
## 12 12_섬유         75    81    88      88     88     63
## 13 15_바이오헬스   114   119   105     114    124    100
## 14 01_ICT         94   100   110     113    101     87
## 15 02_장비        103   108   118     108    116     99
## 16 03_소재         83    92    83      88    106     62
```

```
APPENDIX.2 <- PSI_WEATHER.3 # 완성품 저장
```

- PSI_WEATER.2, PSI_WEATHER.3 만드는 코드를 고치자.
- 객체 네이밍을 순차적으로 했어서, 수정할 부분을 빠르게 찾고, 해당 파트만 교체하는 게 어렵지 않다.

5) 엑셀 출력하기

```
write.xlsx(x = list(APPENDIX.1, APPENDIX.2), # 완성품 두 개를
           sheetName = c('응답자 비율', '기상도'), # 각각의 시트로 갖는
           file = 'PSI 보도자료.xlsx') # 엑셀 파일 생성
```

- 작업 중인 폴더에 엑셀 파일이 생성된다.
- list 클래스는 최상위 레벨로, 앞서 다룬 벡터, 행렬, 데이터프레임 등을 원소로 가질 수 있음.
- 가끔 list를 입력 인자로 요구하는 함수가 있으니 알아두자.

3. Advanced : 미국 수출데이터 가공

```
library(tidyverse)


USTRADE <- read_csv('미국수출 연습용.csv')
```

- UN Commodity Trade 자료의 일부.

```
USTRADE # read_csv() 사용하면 tibble 형태로 저장
```

```
## # A tibble: 82,487 x 35
##    Classification  Year Period `Period Desc.` `Aggregate Level` `Is Leaf Code`
##    <chr>          <dbl>  <dbl>        <dbl>             <dbl>            <dbl>
##  1 H5              2020   2020         2020                 6                1
##  2 H5              2020   2020         2020                 6                1
##  3 H5              2020   2020         2020                 6                1
##  4 H5              2020   2020         2020                 6                1
##  5 H5              2020   2020         2020                 6                1
##  6 H5              2020   2020         2020                 6                1
##  7 H5              2020   2020         2020                 6                1
##  8 H5              2020   2020         2020                 6                1
##  9 H5              2020   2020         2020                 6                1
## 10 H5              2020   2020         2020                 6                1
## # ... with 82,477 more rows, and 29 more variables: `Trade Flow Code` <dbl>,
## #   `Trade Flow` <chr>, `Reporter Code` <dbl>, Reporter <chr>,
## #   `Reporter ISO` <chr>, `Partner Code` <dbl>, Partner <chr>,
## #   `Partner ISO` <chr>, `2nd Partner Code` <lgl>, `2nd Partner` <lgl>,
## #   `2nd Partner ISO` <lgl>, `Customs Proc. Code` <lgl>, Customs <lgl>,
```

```
## #   `Mode of Transport Code` <lgl>, `Mode of Transport` <lgl>,
## #   `Commodity Code` <dbl>, Commodity <chr>, `Qty Unit Code` <dbl>, ...
```

```
USTRADE.1 <- USTRADE %>%
  select(Year, `Trade Flow Code`, `Trade Flow`, `Reporter Code`,
         Reporter, `Partner Code`, Partner, `Partner ISO`,
         `Commodity Code`, Commodity, `Qty Unit Code`, `Qty Unit`,
         Qty, `Trade Value (US$)`) # 필요 변수 선택

USTRADE.1 %>% dim() # 변수 35개 -> 14개
```

```
## [1] 82487    14
```

- 띄어쓰기가 포함된 변수 명은 앞 뒤를 ’’ 내지 “로 감싸야 함.

```
library(haven) # dta 로드 패키지

LINK <- read_dta('연계표 연습용.dta') %>%
  select(hsc, ksic5) # 국제무역코드(hscode), 한국표준산업분류(ksic5)만 선택
```

- STATA를 사용하면 dta 파일로 작업물을 공유하는 경우가 있음.
- R에서는 해당 파일을 haven 패키지를 사용해 입출력.
- 비슷한 방식으로 타 프로그램 사용자와 co-work 가능.

```
LINK
```

```
## # A tibble: 6,564 x 2
##      hsc ksic5
##    <dbl> <dbl>
##  1   223    NA
##  2   284    NA
##  3   285    NA
##  4   286    NA
##  5   287    NA
##  6   288    NA
##  7   289    NA
##  8   290    NA
##  9 10110  1291
## 10 10111  1291
## # ... with 6,554 more rows
```

```
LINK.1 <- LINK %>%
  filter(!is.na(ksic5)) # 한국 분류로의 매칭이 목적이니, ksic5 공란 케이스는 제외

LINK.1 # number of rows가 6564 -> 6552로 축소
```

```
## # A tibble: 6,552 x 2
##      hsc ksic5
##    <dbl> <dbl>
##  1 10110  1291
##  2 10111  1291
##  3 10119  1291
##  4 10120  1291
##  5 10121  1291
##  6 10129  1291
##  7 10130  1291
##  8 10190  1291
##  9 10210  1211
## 10 10221  1211
## # ... with 6,542 more rows
```

- filter(data_table, condition, ...) 함수는 조건에 맞는 observation만 선택.
- is.na() 함수는 결측치, 즉 NA인 경우 TRUE를 출력.
- ! 연산자는 부정, not을 의미.
- 따라서 observation인데, ksic5 변수가 NA인 경우는 배제하고 LINK.1에 저장하겠다는 것.

```
MANUFACTURE_KOREA <- seq(10, 34) # ksic5에서 제조업 파트는 10~34로 시작

temp1 <- rep(0, nrow(LINK.1)) # 영벡터

for (i in seq_along(MANUFACTURE_KOREA)) { # i = 1, 2, ..., 25에 대해 다음 작업 반복

  temp2 <- str_starts(string = as.character(LINK.1$ksic5), # ksic5가
                      pattern = as.character(MANUFACTURE_KOREA[i])) # 제조업 파트로 시작하면 TRUE

  temp1 <- temp1 + temp2 # 사칙연산에서 TRUE = 1이므로, 영벡터에 1 남기게 됨.
```

```
}


temp1 %>% head() # temp1은 제조업인 경우 1이 채워진 벡터
```

```
## [1] 1 1 1 1 1 1
```

```
temp1 %>% sum() # 6413개 observation이 제조업에 해당
```

```
## [1] 6413
```

```
TESTER <- temp1 %>% as.logical() # 논리값으로 변경


TESTER %>% head() # 1은 다시 TRUE로 변환
```

```
## [1] TRUE TRUE TRUE TRUE TRUE TRUE
```

- seq_along(vector) 함수는 1:length(vector) 수열을 출력.
- 논리값은 숫자로 변환하면 0, 1이므로 sum()과 궁합이 좋음.

```
MANUFACTURE_WORLD <- LINK.1[TESTER, ]$hsc # 논리값을 인덱싱에 활용


MANUFACTURE_WORLD %>% head() # 한국 분류로 제조업에 해당하는 hscode
```

```
## [1] 10110 10111 10119 10120 10121 10129
```

```
USTRADE.2 <- USTRADE.1 %>%
 filter(`Commodity Code` %in% MANUFACTURE_WORLD) %>% # 제조업 데이터만 선택
 arrange(Year, `Commodity Code`) %>% # 연도 순, HS code 순으로 정리
 relocate(Year, `Commodity Code`,
          Commodity, `Trade Value (US$)`) # 주요 변수 앞으로 이동


write_csv(USTRADE.2, '미국수출 연계작업.csv') # 정리한 데이터셋을 csv로 저장
```

- x %in% y는 y vector 내에 x라는 인수가 있다면 TRUE를 반환.
- 변수, 객체 이름을 잘 지어야 헷갈리지 않음.

4. Quiz

초급 datasets::mtcars 데이터를 가져와 다음을 해결해보자.

1) 차 이름을 새 변수로 설정해 표시하자. rownames_to_column(var = 'car') 함수를 사용하라.

2) 방금 만든 car, 그리고 mpg(miles per gallon), cyl(number of cylinders), hp(gross horsepower) 변수만을 선택하라.

3) 실린더 당 마력을 계산해 새 변수로 나타내라.

```
# 1, 2, 3)

CAR.1 <- datasets::mtcars %>%
 rownames_to_column(var = 'car') %>%
 tibble() %>%
 select(car, mpg, cyl, hp) %>%
 mutate(hp_per_cyl = hp/cyl)

CAR.1
```

```
## # A tibble: 32 x 5
##    car               mpg   cyl    hp hp_per_cyl
##    <chr>           <dbl> <dbl> <dbl>     <dbl>
##  1 Mazda RX4        21      6   110      18.3
##  2 Mazda RX4 Wag    21      6   110      18.3
##  3 Datsun 710       22.8    4    93      23.2
##  4 Hornet 4 Drive   21.4    6   110      18.3
##  5 Hornet Sportabout 18.7   8   175      21.9
##  6 Valiant          18.1    6   105      17.5
##  7 Duster 360       14.3    8   245      30.6
##  8 Merc 240D        24.4    4    62      15.5
##  9 Merc 230         22.8    4    95      23.8
## 10 Merc 280         19.2    6   123      20.5
## # ... with 22 more rows
```

중급 다음 작업을 이어서 해보자.

1) 1974년 데이터인데, 이 때도 차는 벤츠가 짱이었나보다. 차 이름에 Merc 문자열을 포함한 관측값은 몇 개인가. str_detect(pattern = 'Merc') 함수를 사용하라.

2) 벤츠 차량 데이터만을 추려보자. str_detect() 의 결과값(논리값)을 인덱싱에 사용하라.

3) 벤츠 차량의 평균 마력은 얼마인가.

```
# 1)
```

```
CAR.1$car %>%
 str_detect('Merc') %>%
 sum() # 논리값은 단순 덧셈하면 TRUE = 1, FALSE = 0 으로 계산된다.
```

```
## [1] 7
```

```
# 2)

CAR.2 <- CAR.1[CAR.1$car %>% str_detect('Merc'), ]

CAR.2
```

```
## # A tibble: 7 x 5
##   car          mpg   cyl    hp hp_per_cyl
##   <chr>      <dbl> <dbl> <dbl>     <dbl>
## 1 Merc 240D   24.4     4    62      15.5
## 2 Merc 230    22.8     4    95      23.8
## 3 Merc 280    19.2     6   123      20.5
## 4 Merc 280C   17.8     6   123      20.5
## 5 Merc 450SE  16.4     8   180      22.5
## 6 Merc 450SL  17.3     8   180      22.5
## 7 Merc 450SLC 15.2     8   180      22.5
```

```
# 3)

sum(CAR.2$hp) / 7
```

```
## [1] 134.7143
```

고급 다음 작업을 이어서 해보자.

1) 벤츠 차량의 수, 평균 마력을 구하라. filter()와 summarise() 함수를 사용하라.

```
# 1)

CAR.3 <- CAR.1 %>%
 filter(str_detect(.$car, 'Merc')) %>%
 summarise(number = n(), hp_avg = (sum(hp)/n()))

CAR.3
```

```
## # A tibble: 1 x 2
##   number hp_avg
##    <int>  <dbl>
## 1      7   135.
```

Day 3

1. What is API

Computers' Talk 컴퓨터나 컴퓨터 프로그램 사이의 연결

- language for computer 라서, 사람인 우리가 보고 쓰려면 일정 부분 배워야.
- 사람 보라고 만든 인터페이스는 UI(User Interface), 예컨대 삼성 갤럭시는 One UI 4.1
- API(Application Programming Interface)에 대한 짧은 클립을 추천.
- 노마드코더, API 기초개념 https://youtu.be/iyFHfzCRHA8

Kosis Open API 국가통계포털 공유서비스

- https://kosis.kr/openapi/introduce/introduce_01List.jsp
- 통계 데이터를 프로그램 상에서 바로 로드, 작업할 수 있음.
- 호출키(+인증키), 항목 설정 등으로 이뤄진 URL을 통해 데이터를 받아옴.
- 통계청뿐만 아니라 한은, 공공데이터포털, DART 등 대부분의 정보처는 API 서비스를 제공.

2. Exercise : 서비스업생산지수 업데이트

서비스업 생산지수 http://kosis.kr/statHtml/statHtml.do?orgId=101&tblId=DT_1F01501&conn_path=I2

1) 데이터 이용 신청

최초 사용자가, URL 생성 방식으로 진행함을 가정

- 서비스이용 → 통계자료 탭을 눌러서 간단한 신청 폼을 작성.
- 자료등록 메뉴로 이동, 통계조사명 란에 '서비스업동향조사' 입력하고 검색.
- 서비스업동향조사 내 통계표가 여럿 나오는데, 2페이지의 산업별 서비스업생산지수의 사용여부 체크하고 자료등록.

2) 상세 조건 설정

- URL생성 메뉴로 이동, URL 생성 조건을 설정하자.
- 통계청 포털에서 체크박스 누르던 파트를 옮겨놓은 것.
- 필요한 데이터는 **불변/계절조정지수**의 최근값인데, **1레벨의 총지수**와 **3레벨 모든 항목**이 담겨있어야 함.
- 조회구분 = 시계열 선택
- 분류는 조금 길어서 다음을 순차적으로 진행
- 개별 옆의 선택 버튼 클릭
- 업종별 옆의 부등호를 등호로 교체
- 1을 3으로 교체하고 이동 버튼 클릭 (3레벨 분기로 전환)
- 체크박스 일괄 선택하고, 선택 버튼 눌러서 설정 저장
- 다시 개별 옆의 선택 버튼 클릭
- 총지수도 체크해 선택 버튼 클릭
- 항목의 불변지수, 계절조정지수 체크
- 활용 자료명에 '서비스업생산지수 업데이트' 입력
- URL생성 버튼 클릭
- 너무 많이 선택했다고 에러 사인. 3레벨 산업 분기를 전부 체크한 탓으로 보임.
- 원래는 대용량 데이터로 개별 신청해야 하나, 나름 대응 방안이 있음. 아래서 자세히 설명.
- 우선 불변지수 하나만 체크해서 URL 생성.
- 조금 기다리면 항목별(산업별)로 총 86개의 URL이 만들어짐.

3) 단일 데이터 로드

- 첫 번째 **불변지수x수도업**의 URL 보기를 클릭해보자.
- 해당 URL을 복사해 다음과 같이 로드.

```
library(tidyverse) # 데이터 핸들링
library(jsonlite) # JSON 파일 로드

URL <- 'https://kosis.kr/openapi/statisticsData.do?method=getList&apiKey=<인증키>=&format=json&jsonVD=Y&userS

SERVICE <- fromJSON(URL) %>% tibble()
```

```
SERVICE
```

```
## # A tibble: 3 x 16
##   TBL_NM      PRD_DE TBL_ID ITM_NM ITM_NM_ENG ITM_ID UNIT_NM ORG_ID UNIT_NM_ENG
##   <chr>       <chr>  <chr>  <chr>  <chr>      <chr>  <chr>   <chr>  <chr>
## 1 산업별 서비~ 202201 DT_1K~ 불변~  Volume     T2     2015=~ 101    2015=100
## 2 산업별 서비~ 202202 DT_1K~ 불변~  Volume     T2     2015=~ 101    2015=100
## 3 산업별 서비~ 202203 DT_1K~ 불변~  Volume     T2     2015=~ 101    2015=100
## # ... with 7 more variables: C1_OBJ_NM <chr>, C1_OBJ_NM_ENG <chr>, DT <chr>,
## #   PRD_SE <chr>, C1 <chr>, C1_NM <chr>, C1_NM_ENG <chr>
```

- fromJSON(source, ...) 함수는 URL, 로컬 JSON파일 등을 읽어서 데이터 프레임으로 출력.
- 최근 3개월 자료를 default로 설정해둔 바, 3개의 row가 로드됨.
- 16개의 column이 생성되었는데, 네이밍 요령은 **개발 가이드**란 이름으로 다음에서 제공.
- https://kosis.kr/openapi/devGuide/devGuide_0201List.jsp
- **통계표선택 방법**의 **출력결과** 항목을 보면 해당 column에 어떤 variable이 담겼는지 알 수 있음.

```
temp <- SERVICE %>%
  select(TBL_NM, # 통계표 이름
         PRD_DE, # 시점
         ITM_NM, # 지수(항목)
         C1_NM, # 산업(분류)
         C1, # 산업 코드
         DT) %>% # 지수값
  mutate(DT = as.double(DT)) # 값은 숫자 클래스로 변경

colnames(temp) <- c('통계', '시점', '지수', '산업', '코드', '값') # 직관적인 네이밍으로 변경

SERVICE.1 <- temp

rm(temp) # 임시 객체 삭제

SERVICE.1 # 필요한 값만 정리
```

```
## # A tibble: 3 x 6
##   통계                        시점   지수     산업   코드     값
```

```
##   <chr>                          <chr> <chr>   <chr> <chr> <dbl>
## 1 산업별 서비스업생산지수 (2015=100.0) 202201 불변지수 수도업 E360  108.
## 2 산업별 서비스업생산지수 (2015=100.0) 202202 불변지수 수도업 E360   98.2
## 3 산업별 서비스업생산지수 (2015=100.0) 202203 불변지수 수도업 E360  104.
```

- 다루는 객체가 많아질수록 헷갈리기 마련. 임시 객체를 활용하는 것도 방법.

3. Advanced : 다중 데이터 로드

- 헌데, 이걸 86번 반복할 순 없는 노릇.
- 다시 URL생성 코너로 돌아가, **불변지수x하수, 폐수 및 분뇨 처리업** 의 URL을 확인하자.
- 자세히 보면 **$prdSe** 앞의 숫자가 **2**로 변경돼있다.
- 같은 조건에서 URL을 다중 생성하다보니, 다른 부분은 동일하더라도, 구별 차원에서 숫자를 달리 매겨놓은 것.
- 해당 숫자를 매개로 for() 구문을 사용하면 반복 작업을 할 수 있겠다.
- Day 2의 Advanced에 있던 내용과 유사하다. 아래 코드를 차용해도 좋지만, 가급적 대용량 통계자료 신청 기능을 이용하자.

```
# 0. what do you need

KEY <- '개인 인증키'
ID <- 'Kosis ID'
INDEX.1 <- '불변지수 URL 고유번호'
INDEX.2 <- '계절조정지수 URL 고유번호'
```

- #을 이용한 주석은 코드 실행되지 않는 바, 소제목 대용으로도 좋음.
- 비슷한 내용의 코드라면 덩어리 지어 직관적으로 보이게 하는 것.
- 코드 구성은 같지만, 개인화된 정보를 기입해야 되는 경우가 있음.
- parameter를 앞으로 빼두면 이하 코드에 자동 적용되니 편함.
- 인턴은 이를 what do you need 코너로 만들어 작성하는 편.

```
# 1. setting

library(tidyverse) # 데이터 핸들링
library(jsonlite) # JSON 파일 로드
library(openxlsx) # 엑셀 입출력
```

- 필요한 패키지 로드는 가급적 코드 상단에 작성.
- 물론 코드를 짜면서 패키지를 하나씩 추가하기 마련.
- 다만 정리를 위쪽에 해두자는 것.

```
# 2. url

BASE <- paste0('https://kosis.kr/openapi/statisticsData.do?method=getList', # 요청
               '&apiKey=', KEY, # 인증키
               '&format=json&jsonVD=Y', # 포맷 : JSON
               '&userStatsId=', ID) # 방식 : 사용자가 기등록한 자료 로드
```

- 개인 URL은 여러 부분으로 분기될 수 있음.
- 본 예시에선 &을 기준으로 인자가 나눠짐.
- paste0() 함수로 어차피 합쳐질 테니 코드 상에선 쉼표로 분절하고 엔터, 주석 표시.
- KEY, ID 객체는 앞서 적어둔 값을 받아와 입력.

```
CORE <- c(INDEX.1, INDEX.2) # 불변지수, 계절조정지수 URL 고유번호

NUMBER <- 1:86 # URL 개수
```

- 산업별 86개 자료를 로드하는 데, 그걸 불변/계절조정지수에서 각각 해야함.
- for(k = 1:2, for(i = 1:86, load)) 식으로 loop를 짜야겠다는 생각.
- 물론 실제 코드 작성은 반대로 이뤄짐. like 역진귀납.
- 구체적으로 URL 1개 → 그 코드를 for로 감싸서 URL 84개 → 그걸 또 감싸서 84*2개
- 따라서 내부 코드만 잘 짜두면 반복은 쉬움.
- 작업을 말로 설명할 수 있다면, 그걸 하나씩 코드로 바꿔가면 되는 것.

```
DATA <- tibble() # 데이터 담을 빈 그릇
```

- 아무 인자도 없는 tibble()은 0x0 data frame을 생성.
- Day 2에서 영벡터 만들었던 것과 같은 맥락.

```
# 3. data load

for (k in seq_along(CORE)) { # k = 1, 2에 대해서 다음 작업 실행
```

```
 temp1 <- tibble() # 데이터 담을 빈 그릇

 for (i in seq_along(NUMBER)) { # i = 1, 2, ... , 86에 대해서 다음 작업 실행

  URL <- paste0(BASE, # URL 앞 부분
                '101/', # 통계청
                'DT_1KS2015/', # 산업별 서비스업생산지수(2015=100)
                '2/', # 시계열
                '1/', # 간격 : 1
                CORE[k], '_', NUMBER[i], # URL 나열
                '&prdSe=', 'M', # 주기 : Month
                '&newEstPrdCnt=', '1') # 최근 1개 자료

  temp2 <- tryCatch(fromJSON(URL) %>% # fromJSON ~ select 함수를 실행하되,
                    tibble() %>%
                    mutate(번호 = i) %>%
                    select(번호, PRD_DE, ITM_NM, C1_NM, C1, DT),
                    error = function(e) tibble(NULL)) # 오류(데이터 부재) 발생하면 스킵

  temp1 <- rbind(temp2, temp1) # stacking

 }

 temp3 <- temp1 %>%
  arrange(nchar(C1), C1) %>% # 분류값 순으로 정렬
  mutate_at(vars(DT), as.double) # 수치값 class 숫자로 변경

 DATA <- rbind(temp3, DATA) # stacking

}
```

- 용례가 어렵지만, rbind(a, b)는 자주 등장하는 기본 함수.
- 같은 column으로 구성된 a, b 데이터를 row 연장해서 붙임.
- 5x10, 10x10 데이터 테이블을 rbind()로 묶는다면, 15*10 데이터 테이블이 됨.
- 여기선 0x0, 1x6 데이터를 묶어서 저장하고, 그 1x6 데이터에 새로운 1x6을 더하고…

- (n+1)x6 = nx6 + 1x6 식으로 지정해 쌓아가는 것.
- tryCatch(function, 에러대처, ...) 함수는 간혹 통계 데이터가 없어서 에러, loop 정지되는 경우가 있기에 작성.
- 이런 게 역진으로 올라가면서 생기는 문제고, generalize 과정이겠음.
- arrange(condition1, condition2, ...)는 row 순서를 해당 조건에 맞춰 정렬해줌.
- condition1을 맞추고, condition2를 이어 맞추는 식.
- 여기선 코드의 자릿수(짧으면 1레벨, 길면 3레벨이니까)로 맞추고, 이어서 코드 문구로 맞춤.

```
# 4. finish

rm(list = c('temp1', 'temp2', 'temp3')) # 임시 객체 삭제

colnames(DATA)[2:6] <- c('시점', '지수', '산업', '코드', '값') # 변수명 변경

# 5. export

write.xlsx(DATA, '서비스업생산지수 업데이트.xlsx') # 엑셀 파일로 저장
```

- 여기까지 덥석 이해했다면, 당신은 본 강의 레벨을 아득히 넘는다.

```
read.xlsx('서비스업생산지수 업데이트.xlsx') %>%
  tibble() %>%
  select(-1) # 첫 번째 열은 삭제
```

```
## # A tibble: 172 x 5
##    시점   지수        산업                    코드     값
##    <chr>  <chr>       <chr>                   <chr> <dbl>
##  1 202203 계절조정지수 총지수                  T     114.
##  2 202203 계절조정지수 수도업                  E360  107.
##  3 202203 계절조정지수 하수 폐수 및 분뇨 처리업 E370   96.4
##  4 202203 계절조정지수 자동차 판매업           G451  123.
##  5 202203 계절조정지수 자동차 부품 및 이륜차 판매업 G452  116.
##  6 202203 계절조정지수 산업용 농축산물 도매업   G462  110.
##  7 202203 계절조정지수 음 · 식료품 및 담배 도매업 G463  110.
##  8 202203 계절조정지수 생활용품 도매업         G464  104.
##  9 202203 계절조정지수 기계장비 및 관련 물품 도매업 G465  122.
## 10 202203 계절조정지수 건축자재 도매업         G466   90.4
```

```
## # ... with 162 more rows
```

- 번호는 오류 체크용(오류나면 해당 번호 부재)으로 만들었던지라, 최종 결과물에 굳이 담을 필요는 없음.

Day 4

1. What is Selenium

2. Exercise : 업무포털 로그인

```
library(tidyverse) # 데이터 핸들링
library(rstudioapi) # 터미널 사용
library(RSelenium) # 크롬 자동화
library(rvest) # html 해석

ID <- '포털 아이디'
PW <- '포털 비밀번호'

TERM_COMMAND <- 'java -Dwebdriver.gecko.driver="geckodriver.exe" -jar selenium-server-standalone-4.0.0-alpha-1
terminalExecute(command = TERM_COMMAND) # RStudio Terminal 탭 열어서 상기 커맨드 입력
REMDR = remoteDriver(port = 4445, browserName = 'chrome') # 브라우저로 크롬 선택

REMDR$open() # 크롬 오픈

REMDR$navigate('https://ep.kiet.re.kr/index.do') # 업무 포털 접속해서

BUTTON_LOGIN <- REMDR$findElement('xpath', '//*[@id="f_login"]/ul/li[3]') # 로그인 버튼
TEXT_ID <- REMDR$findElement('xpath', '//*[@id="loginId"]') # 아이디 입력창
TEXT_PW <- REMDR$findElement('xpath', '//*[@id="pwd"]') # 패스워드 입력창을 찾아내고

TEXT_ID$sendKeysToElement(list(ID)) # 아이디 입력
TEXT_PW$sendKeysToElement(list(PW)) # 패스워드 입력
BUTTON_LOGIN$clickElement() # 로그인 버튼 클릭
```

3. Advanced : 아이유 Top 100 수록곡

```
# melon

# 1. setting

library(tidyverse)
library(rstudioapi)
library(RSelenium)
library(rvest)
library(openxlsx)

# 2. selenium

TERM_COMMAND <- 'java -Dwebdriver.gecko.driver="geckodriver.exe" -jar selenium-server-standalone-4.0.0-alpha-
terminalExecute(command = TERM_COMMAND) # 개인 컴퓨터에서 잘 안 되는 경우 java 설치, 방화벽 개인/공용 설정 권장

REMDR = remoteDriver(port = 4445, browserName = 'chrome')
REMDR$open() # 크롬 오픈

# 3. crawling

PERIOD <- 2000:2021

MASTERPIECE <- tibble()

for (i in seq_along(PERIOD)) {

 URL <- paste0('https://www.melon.com/chart/age/index.htm',
               '?chartType=YE',
               '&chartGenre=KPOP',
               '&chartDate=', PERIOD[i])

 REMDR$navigate(URL)

 temp1 <- REMDR$getPageSource()
```

```
TITLE <- read_html(temp1[[1]]) %>%
  html_elements('form#frm') %>%
  html_elements('div.wrap_song_info') %>%
  html_elements('div.ellipsis.rank01') %>%
  html_text() %>%
  str_remove_all('₩n') %>%
  str_remove_all('₩t') %>%
  str_sub(end = -2)

SINGER <- read_html(temp1[[1]]) %>%
  html_elements('form#frm') %>%
  html_elements('div.wrap_song_info') %>%
  html_elements('div.ellipsis.rank02') %>%
  html_text() %>%
  str_sub(end = nchar(.)/2)

ALBUM <- read_html(temp1[[1]]) %>%
  html_elements('form#frm') %>%
  html_elements('div.wrap_song_info') %>%
  html_elements('div.ellipsis.rank03') %>%
  html_text() %>%
  str_remove_all('₩n') %>%
  str_remove_all('₩t')

LIKE <- read_html(temp1[[1]]) %>%
  html_elements('button.btn_icon.like') %>%
  html_text() %>%
  str_remove_all('좋아요₩n₩n총건수₩n') %>%
  str_remove_all(',') %>%
  as.integer()

temp2 <- tibble(YEAR = PERIOD[i], RANK = 1:100,
                TITLE, SINGER, ALBUM, LIKE)

MASTERPIECE <- rbind(MASTERPIECE, temp2)
```

```
  Sys.sleep(5 + rnorm(1))

}

# 4. export(save)

write.xlsx(MASTERPIECE, '멜론차트.xlsx')
```

```
# 5. import

MELON <- read.xlsx('멜론차트.xlsx') %>% tibble()

# 6. analysis

# 6-1. TOP100 수록곡이 가장 많은 가수는?

SUPERSTAR <- MELON %>%
  distinct(TITLE, .keep_all = TRUE) %>%
  group_by(SINGER) %>%
  summarise(NUMBER = n()) %>%
  arrange(desc(NUMBER))

SUPERSTAR
```

```
## # A tibble: 651 x 2
##    SINGER        NUMBER
##    <chr>          <int>
##  1 BIGBANG (빅뱅)    31
##  2 아이유            31
##  3 다비치            25
##  4 방탄소년단        23
##  5 SG 워너비         22
##  6 2NE1              18
##  7 MC몽              18
##  8 백지영            16
##  9 케이윌            16
```

```
## 10 성시경            15
## # ... with 641 more rows
```

```
# 6-2. 아이유의 TOP100 수록곡은?

DLWLRMA <- MELON %>%
  filter(SINGER %in% c('아이유', 'IU')) %>%
  arrange(desc(LIKE), RANK) %>%
  distinct(TITLE, .keep_all = TRUE)

DLWLRMA
```

```
## # A tibble: 31 x 6
##    YEAR  RANK TITLE                          SINGER ALBUM       LIKE
##   <dbl> <dbl> <chr>                          <chr>  <chr>      <dbl>
##  1  2017     2 밤편지                         아이유 밤편지    440455
##  2  2020     5 에잇(Prod.&Feat. SUGA of BTS)  아이유 에잇      377404
##  3  2020     6 Blueming                       아이유 Love poem 335354
##  4  2020    29 Love poem                      아이유 Love poem 325406
##  5  2021     1 Celebrity                      아이유 IU 5th A~ 317773
##  6  2017    67 가을 아침                      아이유 꽃갈피 둘 287467
##  7  2018    46 삐삐                          아이유 삐삐      286851
##  8  2017     7 팔레트 (Feat. G-DRAGON)       아이유 Palette   279988
##  9  2014     4 금요일에 만나요 (Feat. 장이정 Of HISTORY) 아이유 Modern T~ 268366
## 10  2021     5 라일락                         아이유 IU 5th A~ 238361
## # ... with 21 more rows
```

```
# 6-3. 연도별 아이유 LIKE 총량은?

UAENA <- MELON %>%
  filter(SINGER %in% c('아이유', 'IU')) %>%
  group_by(YEAR) %>%
  summarise(HEART = sum(LIKE))

UAENA
```

```
## # A tibble: 13 x 2
##    YEAR   HEART
```

```
##    <dbl>  <dbl>
##  1  2009   36484
##  2  2010   98675
##  3  2011  418547
##  4  2012  332969
##  5  2013  127111
##  6  2014  691169
##  7  2015  899371
##  8  2016  192534
##  9  2017 1606544
## 10  2018  727306
## 11  2019 1388066
## 12  2020 1399919
## 13  2021 2585607
```

```r
# 6-4. 아이유의 성장은 계속될까?

UAENA_GRAPH <- UAENA %>%
  ggplot(aes(x = YEAR, y = log(HEART))) +
  geom_point() +
  geom_smooth(formula = y ~ poly(x, 3), method = 'lm')

UAENA_GRAPH
```

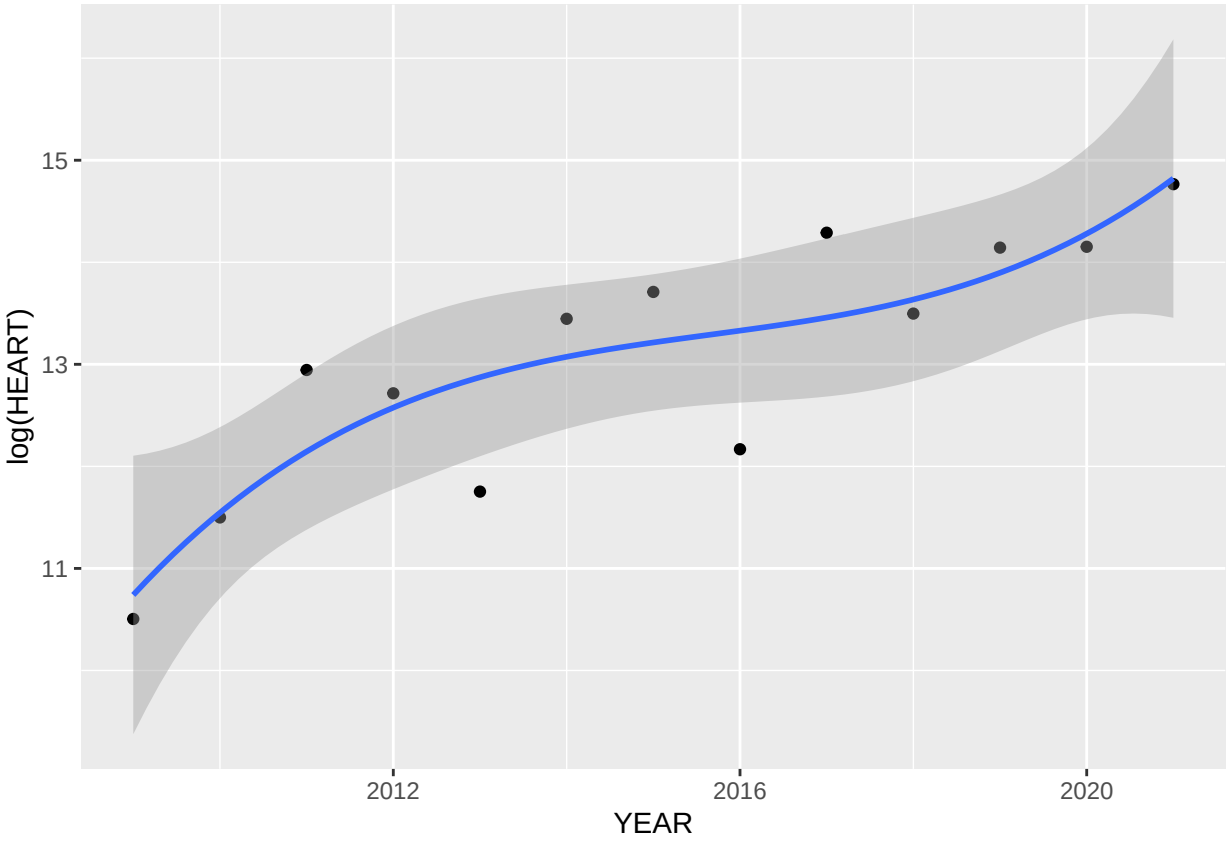
15
13
11
log(HEART)
2012
2016
2020
YEAR